

UNIVERSIDAD DEL VALLE DE GUATEMALA

Colegio Universitario

Libro de Códigos

Proyecto No. 1 - Obtención y Limpieza de Datos

Jose Ordoñez - 231329

Adrián González - 23152

José Antón - 221041

Gadiel Ocaña - 231270

Data Science - Sección 10

Guatemala, 2026

Información general del conjunto de datos

Fuente de los datos	Ministerio de Educación de Guatemala - Sistema de e-Servicios (http://www.mineduc.gob.gt/BUSCA
Fecha de extracción	24 de julio de 2026
Versión del conjunto limpio	v1.1 - datos_establecimientos_limpio.csv (incluye corrección de CIUDAD CAPITAL/ZONA N y de err
Nivel escolar filtrado	Diversificado
Registros	11,347
Variables	17 originales + 2 auxiliares de trazabilidad (ZONA_CIUDAD, TELEFONO_original)

CODIGO

Descripción	Identificador único del establecimiento educativo asignado por el MINEDUC.
Tipo de dato	Texto (character)
Dominio permitido	Cadena alfanumérica con formato NN-NN-NNNN-NN.
Valores posibles	Un código distinto por establecimiento (0 códigos repetidos con datos contradictorios).
Tratamiento aplicado en la limpieza	Se aplicó str_squish(); se descartaron registros sin código o que no cumplieran el patrón NN-NN al inicio; se verificó unicidad (0 duplicados exactos).

DISTRITO

Descripción	Código del distrito educativo al que pertenece el establecimiento.
Tipo de dato	Texto (character)
Dominio permitido	Código alfanumérico tipo NN-NNN.
Valores posibles	508 valores faltantes (4.48%); resto son códigos de distrito.
Tratamiento aplicado en la limpieza	Conservado como texto para no perder ceros a la izquierda ni guiones. Valores faltantes/marcadores especiales estandarizados a NA.

DEPARTAMENTO

Descripción	Departamento de Guatemala donde se ubica el establecimiento.
Tipo de dato	Factor
Dominio permitido	Catálogo oficial de 22 departamentos de Guatemala.
Valores posibles	21 departamentos presentes (Petén no disponible en el portal de origen).
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados. Los 2,159 registros con el valor ficticio "CIUDAD CAPITAL" (código "00") se reasignaron a "GUATEMALA", preservando la zona original en ZONA_CIUADAD.

MUNICIPIO

Descripción	Municipio donde se ubica el establecimiento.
Tipo de dato	Factor
Dominio permitido	Catálogo oficial de municipios asociados a su departamento (340 a nivel nacional).
Valores posibles	318 municipios presentes en el conjunto de datos tras la corrección.
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados. Los valores "ZONA 1" a "ZONA 25" se reasignaron a "GUATEMALA". Se corrigieron 3 errores ortográficos (QUEZALTEPEQUE, PACHALUN, SAN MIGUEL PANAM). 8 variantes que el MINEDUC nombra distinto al catálogo (p. ej. "SAN MIGUEL TUCURU") se documentan como alias válidos, no como error.

ESTABLECIMIENTO

Descripción	Nombre oficial del centro educativo.
Tipo de dato	Texto (character)
Dominio permitido	Texto libre, sin dominio cerrado.
Valores posibles	Nombre tal como lo registra el MINEDUC; no se corrige ortografía por lineamiento del proyecto.
Tratamiento aplicado en la limpieza	Se eliminaron espacios/caracteres invisibles y puntuación repetida. Se buscaron duplicados parciales por similitud Jaro-Winkler (≥ 0.93) dentro del mismo municipio; los casos con similitud 1 se documentaron para revisión manual, sin eliminar registros.

DIRECCION

Descripción	Dirección física del establecimiento.
Tipo de dato	Texto (character)
Dominio permitido	Texto libre.
Valores posibles	65 valores faltantes (0.57%).
Tratamiento aplicado en la limpieza	Normalización de espacios, caracteres invisibles y puntuación repetida. Valores faltantes conservados como NA, sin imputar.

TELEFONO

Descripción	Número de contacto del establecimiento.
Tipo de dato	Texto (character)
Dominio permitido	8 dígitos numéricos con formato NNNN-NNNN.
Valores posibles	1,129 valores faltantes (9.95%); el resto sigue el formato NNNN-NNNN.
Tratamiento aplicado en la limpieza	Se removió cualquier carácter no numérico (guiones, la palabra "FAX", comas). Los que quedaron con exactamente 8 dígitos se reformatearon como NNNN-NNNN; el resto se marcó como NA. El valor original (antes de esta limpieza) se conserva en la variable auxiliar TELEFONO_original.

SUPERVISOR

Descripción	Nombre del supervisor educativo asignado al establecimiento.
Tipo de dato	Texto (character)
Dominio permitido	Texto libre.
Valores posibles	511 valores faltantes (4.50%).
Tratamiento aplicado en la limpieza	Normalización de espacios y caracteres invisibles. Valores faltantes conservados como NA, sin imputar.

DIRECTOR

Descripción	Nombre del director del establecimiento.
Tipo de dato	Texto (character)
Dominio permitido	Texto libre.
Valores posibles	1,724 valores faltantes (15.20%); es la variable con más datos faltantes del conjunto.
Tratamiento aplicado en la limpieza	El marcador "--" (y equivalentes) se reemplazó por NA. Normalización de espacios y caracteres invisibles. No se imputan nombres de directores.

NIVEL

Descripción	Nivel educativo que ofrece el establecimiento (variable cualitativa ordinal).
Tipo de dato	Factor
Dominio permitido	Niveles del sistema educativo guatemalteco, filtrados hasta Diversificado.
Valores posibles	DIVERSIFICADO (único valor, por el filtro aplicado en la obtención de datos).
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados; convertida a factor.

SECTOR

Descripción	Sector administrativo al que pertenece el establecimiento.
Tipo de dato	Factor
Dominio permitido	{OFICIAL, PRIVADO, MUNICIPAL, COOPERATIVA}
Valores posibles	COOPERATIVA, MUNICIPAL, OFICIAL, PRIVADO.
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados; convertida a factor.

AREA

Descripción	Área geográfica donde se ubica el establecimiento.
Tipo de dato	Factor
Dominio permitido	{URBANA, RURAL, SIN ESPECIFICAR}
Valores posibles	RURAL, SIN ESPECIFICAR, URBANA.
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados; convertida a factor. "SIN ESPECIFICAR" se conserva como categoría propia del MINEDUC, no como valor faltante.

STATUS

Descripción	Estado operativo del establecimiento.
-------------	---------------------------------------

Tipo de dato	Factor
Dominio permitido	{ABIERTA, CERRADA DEFINITIVAMENTE, CERRADA TEMPORALMENTE, TEMPORAL NOMBRAMIENTO, TEMPORAL TITULOS}
Valores posibles	Los 5 valores del dominio están presentes.
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados; convertida a factor.

MODALIDAD

Descripción	Modalidad lingüística de enseñanza.
Tipo de dato	Factor
Dominio permitido	{MONOLINGUE, BILINGUE}
Valores posibles	BILINGUE, MONOLINGUE.
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados; convertida a factor.

JORNADA

Descripción	Jornada horaria en la que opera el establecimiento.
Tipo de dato	Factor
Dominio permitido	{MATUTINA, VESPERTINA, NOCTURNA, DOBLE, INTERMEDIA, SIN JORNADA}
Valores posibles	Los 6 valores del dominio están presentes.
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados; convertida a factor.

PLAN

Descripción	Plan de estudios bajo el cual opera el establecimiento.
Tipo de dato	Factor
Dominio permitido	13 categorías administrativas (DIARIO(REGULAR), FIN DE SEMANA, SABATINO, DOMINICAL, A DISTANCIA, VIRTUAL A DISTANCIA, entre otras).
Valores posibles	13 valores distintos presentes en el conjunto de datos.
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados; convertida a factor.

DEPARTAMENTAL

Descripción	Dirección Departamental de Educación responsable administrativamente del establecimiento.
Tipo de dato	Factor

Dominio permitido	25 direcciones departamentales (algunos departamentos, como Guatemala y Quiché, se dividen en varias direcciones departamentales).
Valores posibles	25 valores distintos presentes (p. ej. GUATEMALA NORTE, GUATEMALA SUR, GUATEMALA ORIENTE, GUATEMALA OCCIDENTE, QUICHÉ, QUICHÉ NORTE).
Tratamiento aplicado en la limpieza	Mayúsculas y espacios normalizados; convertida a factor. Se verificó consistencia con DEPARTAMENTO (todas las combinaciones observadas son coherentes).

ZONA_CIUDAD (derivada)

Descripción	Número de zona de la Ciudad de Guatemala, extraído del valor original de MUNICIPIO cuando este era "ZONA N".
Tipo de dato	Texto (character)
Dominio permitido	Números del 1 al 25, o NA para el resto del país.
Valores posibles	9,188 valores NA (establecimientos fuera de la ciudad capital); 2,159 registros con un número de zona.
Tratamiento aplicado en la limpieza	Variable derivada. Por qué se creó: para no perder el detalle de la zona al reasignar "CIUDAD CAPITAL"/"ZONA N" a DEPARTAMENTO=MUNICIPIO="GUATEMALA". Cómo se calculó: se extrajo el número contenido en el MUNICIPIO original con una expresión regular. Utilidad: permite análisis a nivel de zona de la ciudad capital sin alterar la estructura estándar de departamento/municipio.

TELEFONO_original (derivada)

Descripción	Valor de TELEFONO tal como venía en el archivo crudo, antes de normalizar el formato.
Tipo de dato	Texto (character)
Dominio permitido	Texto libre (formatos variados: con/sin guion, con la palabra "FAX", separación por coma, etc.).
Valores posibles	Igual de completitud que TELEFONO antes de la limpieza.
Tratamiento aplicado en la limpieza	Variable derivada. Por qué se creó: para dejar trazabilidad de la limpieza de TELEFONO y poder auditar cada reformato. Cómo se calculó: copia directa de TELEFONO antes de aplicarle la limpieza de formato. Utilidad: permite verificar manualmente cualquier número que haya quedado como NA tras la limpieza.

Nota de fuente y versión (aplica a todas las variables)

Fecha de extracción: 24 de julio de 2026. Fuente: Ministerio de Educación de Guatemala, Sistema de e-Servicios (http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/), nivel escolar Diversificado, 22 archivos CSV (uno por departamento; Petén no estaba disponible). Versión del conjunto limpio: v1.1, generada a partir de `datos_establecimientos_limpio.csv` tras aplicar la corrección de CIUDAD CAPITAL/ZONA N y de los errores ortográficos de municipio documentados en el registro de transformaciones.